Работа с СУБД SQL

Индексы.

Проверить, идет ли запись

Меня хорошо видно && слышно?

Проверка

- настройка микрофона и аудио
- проверка работы чата

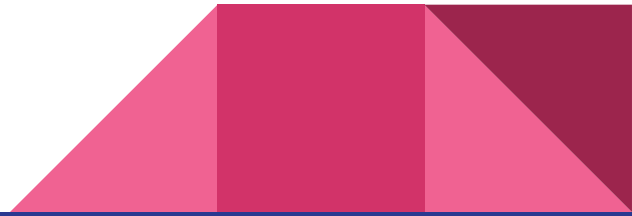

Индексы. Структуры данных.

Индекс

- служебная структура данных
- некий способ отображения ключа в данные
- ускоряют поиск, сортировку
- требуют доп. место для хранения
- обновляются при вставке (модификации данных)

Пример из жизни - оглавление

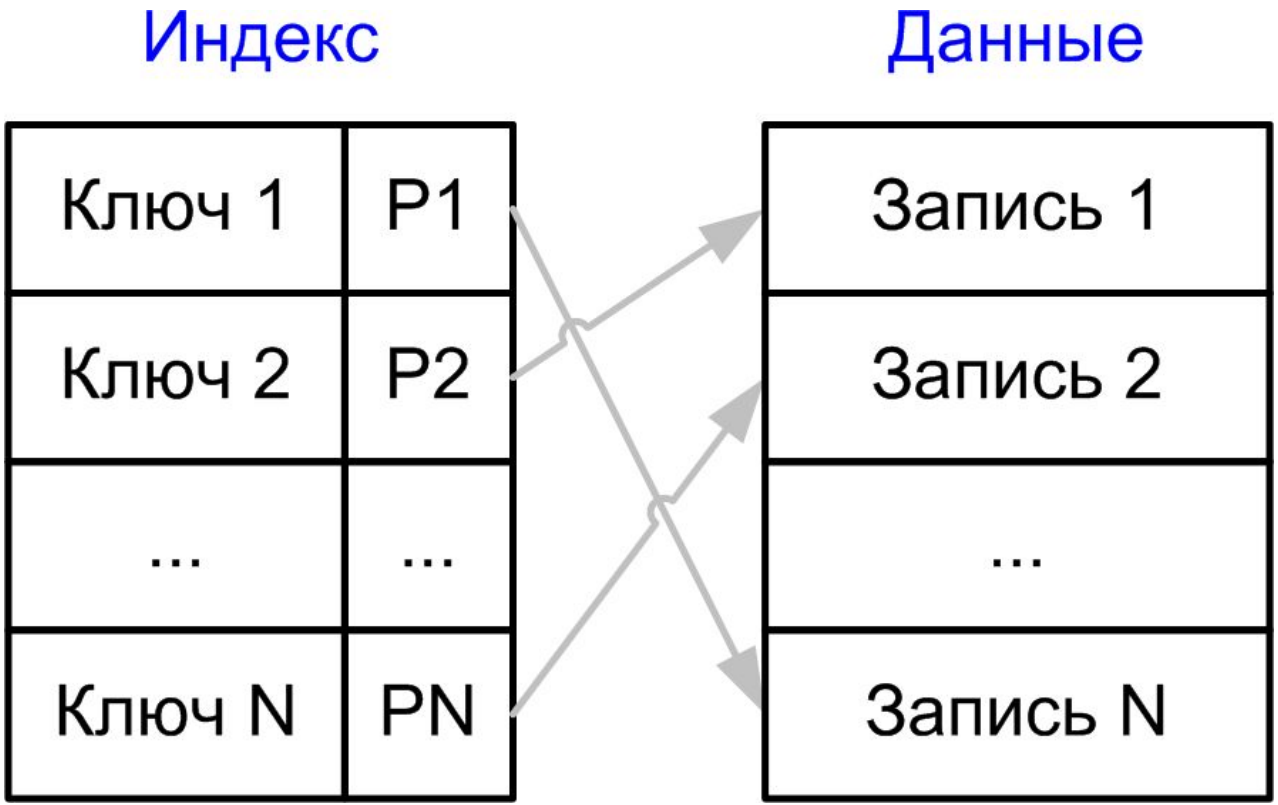

Какие индексы бывают

Уникальные	Не уникальные
Простые	Составные
Кластерные	Некластерные

Вопрос

Много индексов - хорошо или не очень?

Применимость

- **Ускоряют запросы**
- **Позволяют делать constraints (UNIQUE, FOREIGN KEY)**

У нас много данных

- оперативная память очень ограничена
- будем использовать внешний носитель (привет, медленный HDD)
- logN обращений к медленной памяти

Можем ли мы придумать что-то лучше?!

B-tree

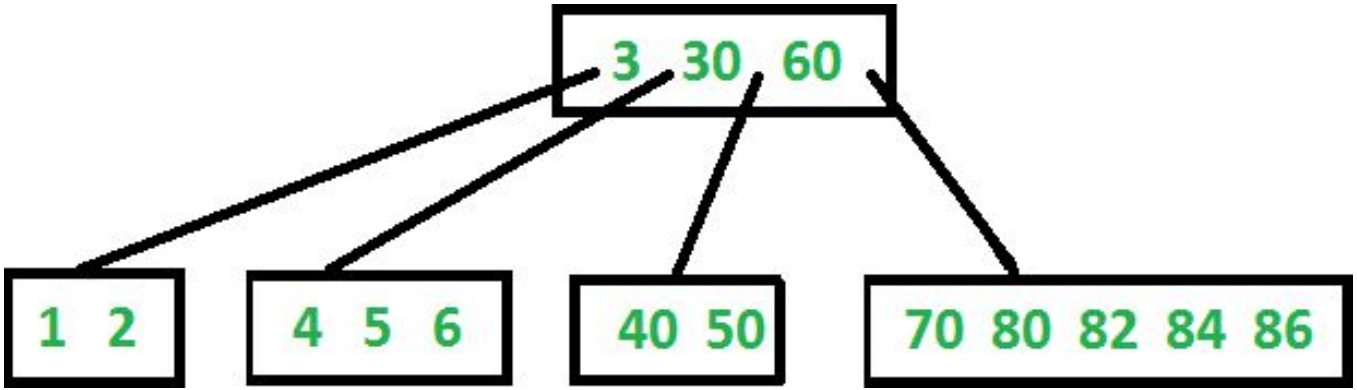

Характеристики

- сильно ветвистое сбалансированное дерево
- t - минимальная степень
- минимум t - 1, не более 2t -1 ключей (кроме корневого) небольшая высота дерева

Поиск в B-tree

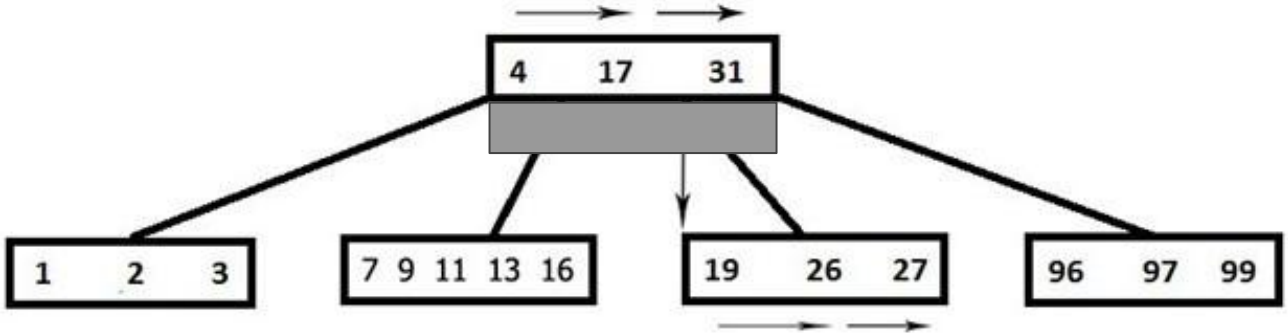

Поиск в B-tree

- алгоритм аналогичен бинарному, но дальнейший выбор не из 2х, а из нескольких
- поиск за O(t logt(n))
- НО обращений к диску O(logt(n))

Добавление в B-tree

Дано:
- t=3
- вставляем 15

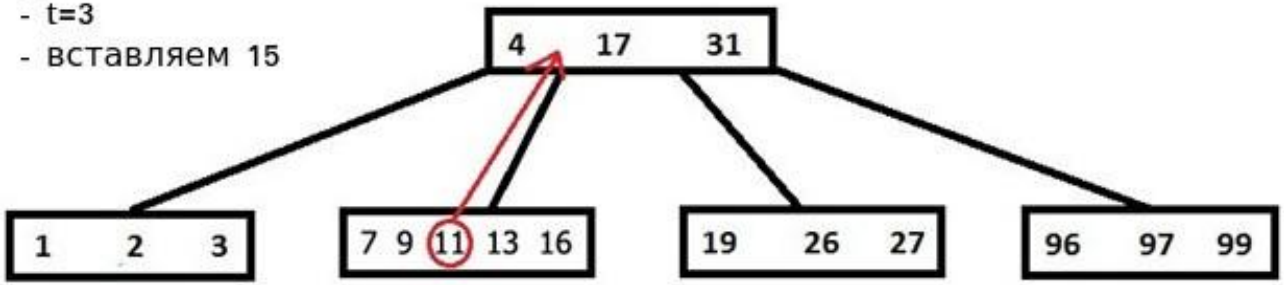

Добавление в B-tree

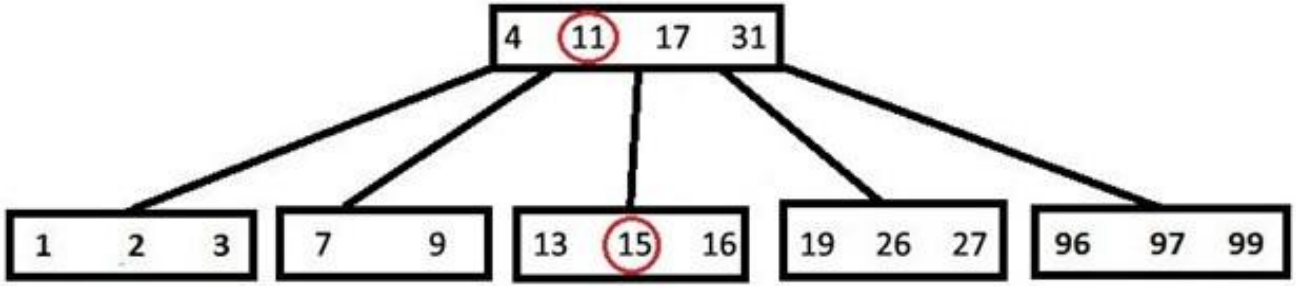

Добавление в B-tree

- нельзя добавить ключ в уже заполненный узел
- разбиение на 2 по t-1 элементу может
- привести к увеличение высоты
- добавление за O(t logt(n))
- НО обращений к диску O(logt(n))

Какой t мне взять?

- больше t => меньше высота дерева
- зависит от размера блока на диске
- зависит от объема оперативной памяти
- обычно от 50 до 2000
- t=1001 и 1млрд записей => 3 операции для любого ключа

B+tree. Поиск по равенству = 38

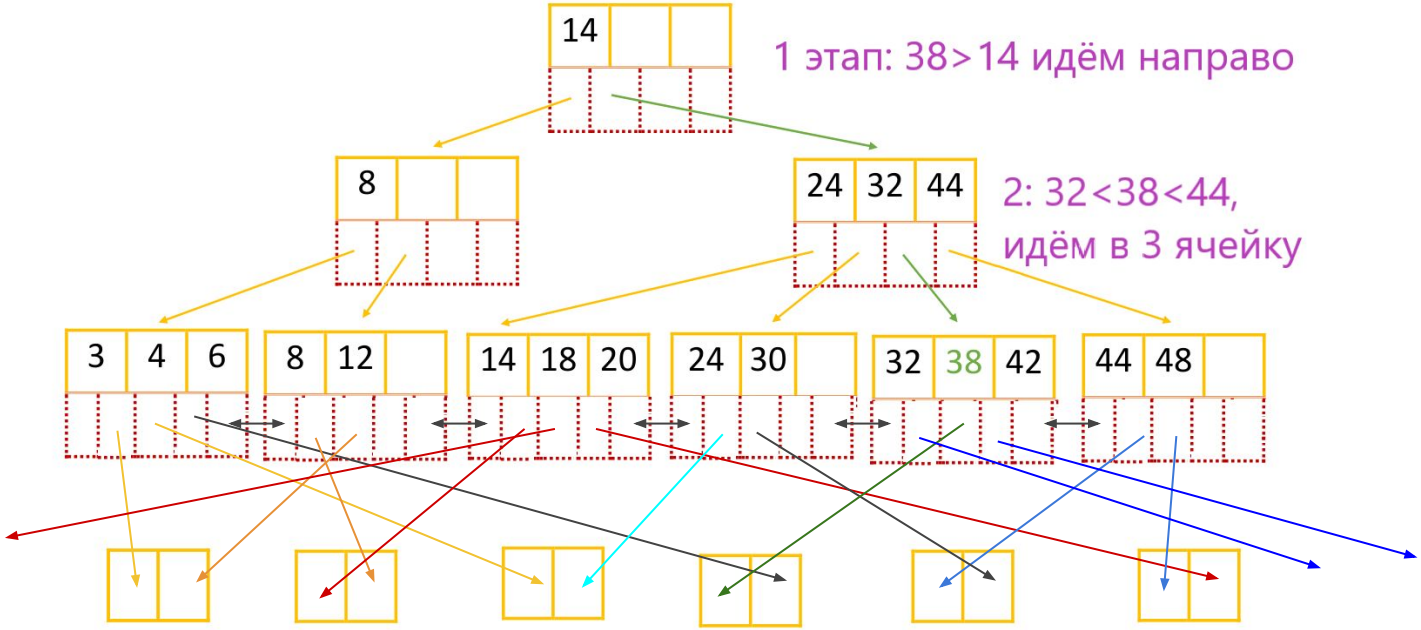

B+tree. Поиск по неравенству < 38

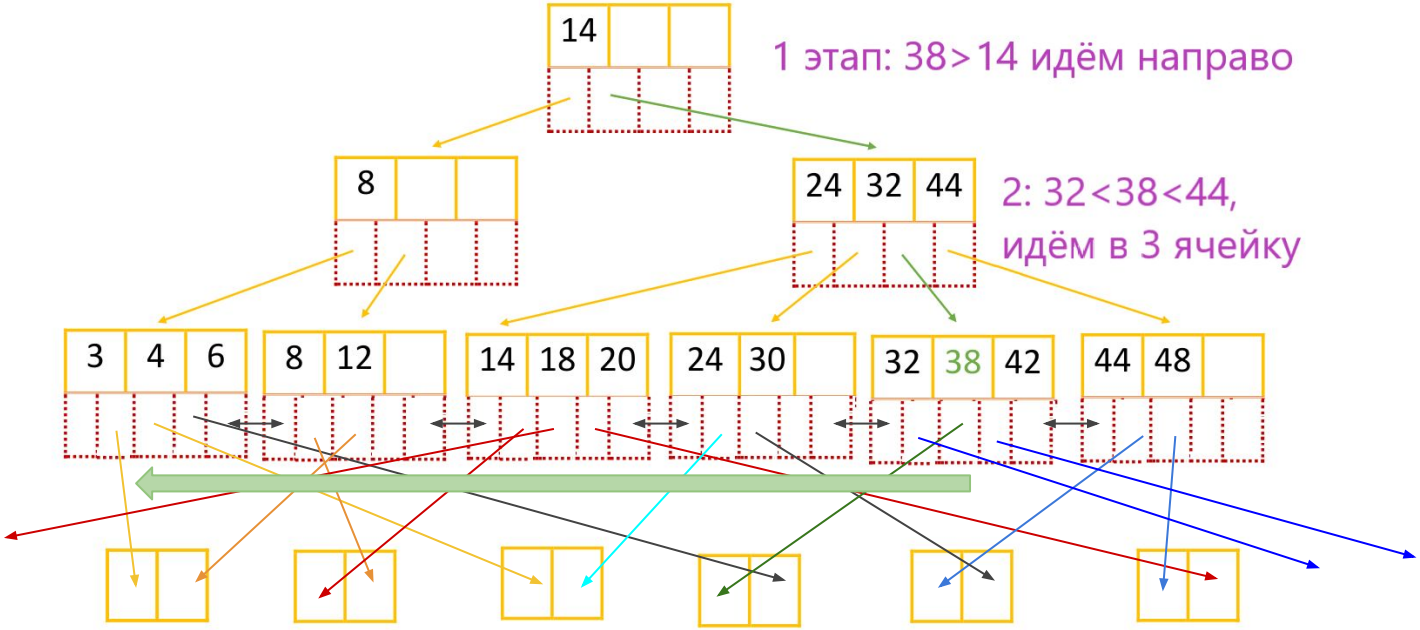

СМОТРИ В БУДУЩЕЕ. ИНВЕСТИРУЙ В ЗНАНИЯ.

Индексы. Практика.

Индексы в Postgres

- Btree
- Hash
- GIST
- SP-GIST
- GIN
- BRIN
- Функциональные
- Частичные

Составные индексы

- **Индекс может быть многоколоночным**
- **Порядок столбцов в индексе ВАЖЕН**
- **В дерево пишется весь кортеж (5, 3, 4)**
- **Правило сравнения работает слева-направо: (1, 2, 3) < (1, 3, 1)**
- **Выбирайте индекс с большим количеством полей: (usr_id) и (usr_id, added)**

Кейс

- Сайт состоит из постов и комментариев к ним
- Таблица с постами
- Таблица с комментариями (comment_id (PK), post_id, time, author, ...)
- Пользователь жалуется, что сайт при попытке посмотреть комментарии к посту тормозит
- Что можно сделать с базой?

Решение

selct * from comments where post_id = 1

Сделаем в качестве PRIMARY KEY (post_id, comment_id)
comment_id UNIQUE NOT NULL

или

IDX (post_id)

Как Postgres использует индексы?

- **Поиск данных**
- **Сортировка**
- **Избежание чтения из таблицы (покрывающие/covering индексы)**
- **Специальные оптимизации**

Проектирование

- **uuid text - 32 байта - uuid uuid 16 байт**
- **Меньше индексов - лучше**
- **Меньше джойнов - лучше**
- **Составные типы данных вместо отдельных таблиц**

Покрывающий индекс

Если решили идти по индексу, а он содержит уже все необходимые данные, то в таблицу не лезем.

Можно включить неиндексируемые поля с помощью INCLUDE

Кластерный индекс

В результате кластеризации таблицы её содержимое физически переупорядочивается в зависимости от индекса. Кластеризация является одноразовой операцией: последующие изменения в таблице нарушают порядок кластеризации

https://www.postgresql.org/docs/current/sql-cluster.html

Готовим данные

```
CREATE TABLE tbl (
    id SERIAL NOT NULL PRIMARY KEY,
    a bigint NOT NULL,
    b bigint NOT NULL,
    c bigint NOT NULL,
    d bigint NOT NULL,
    e bigint NOT NULL,
    str text NOT NULL
);
INSERT INTO tbl (a,b,c,d,e,str)
SELECT random()*1000, random()*1000, random()*1000, random()*1000,random()*1000,
md5(random()::text
FROM generate_series(1, 200000) s(i);
```

Запросы на поиск

```
create index a on tbl(a);
select a, b from tbl where a = 1
```

```
create index a_b on tbl(a,b);
select a, b from tbl where a=1 and b=3;
```

- **Поиск работает по префиксам индексов.**
- **Используем explain!**

Запросы на поиск

```
create index a_b_c on tbl(a, b, c)
```

Хорошие запросы: where

- **a=0**
- **a>0**
- **a=0 and b>4**
- **a=0 and b=2**
- **a=0 and b=2 and c>4**
- **a = 0 and b in (2, 4) and c > 3**

Запросы на поиск

Плохие запросы: where

- **b = 6**
- **b > 3**

Частичное использование индексов:

- **a>0 and b=4**
- **a=0 and b>3 and c=2**
- **a=0 and b>2 and c>3**

Запросы на поиск

Срабатывает ли покрывающий индекс (индекс на a, b, c)?

```
select a, b from tbl where a=0 and b=3

select a,b,c from tbl where a=0 and b=3

select a,b,c,d from tbl where a=0 and b=3

select a,b,c,id from tbl where a=0 and b=3
```

EXPLAIN

```
                                                    QUERY PLAN
-----------------------------------------------------------------------------------------------------------------------
 Index Only Scan using a_b_c on tbl  (cost=0.42..7.90 rows=199 width=16) (actual time=1.453..1.574 rows=202 loops=1)
   Index Cond: (a = 60)
   Heap Fetches: 0
 Planning Time: 0.996 ms
 Execution Time: 1.686 ms
(5 rows)
```

Виды проходов по индексу

- **Seq Scan - последовательный просмотр таблицы**
- **Index Scan - просмотр по индексу и в таблице**
- **Index Only Scan - просмотр по индексу без обращения к таблице**
- **Bitmap Heap Scan - оптимизация с построения битовых карт для поиска**

Сортировка

Хорошие запросы:

select * from tbl

- order by a limit 10;
- where a=1 order by b limit 10;
- where a>0 order by a limit 10;
- order by a desc, b desc limit 10;
- order by a asc, b asc limit 10;

Когда индексы не работают

- Часть выражения: a + 1 = 3, a = func(2)
- Преобразование типов: str = 1
- Несоответствие кодировок
- Индекс не существует или невалидный
- Используется дубликат этого индекса

Как выбирается индекс

- План выбирается динамически с учетом «костов»
- Использование таблицы статистики

Доп.материал

-- Простой индекс
https://www.db-fiddle.com/f/chBbJBYj6GMdyqCxXLBPEG/1

-- Уникальный индекс
https://www.db-fiddle.com/f/4FcEUB9zDZZWnkcJLvEqUq/2

-- Составной индекс
https://www.db-fiddle.com/f/v4KvbgaVVD4NDDjCBq4x5f/1

-- особенности использования 2 и далее индексов в составном
https://www.db-fiddle.com/f/v4KvbgaVVD4NDDjCBq4x5f/3

Доп.материал

-- Покрывающий индекс
https://www.db-fiddle.com/f/33g3xrNmhpCt3a65rEUJJf/1

-- Функциональный индекс
https://www.db-fiddle.com/f/TZpqd6F4zofvbGCn1TOaR/0

-- Частичный индекс
https://www.db-fiddle.com/f/8bJbb6bZUTD8mQpq5v7Wvd/0

ДЗ №4

https://github.com/DWH-course-examples/SQL-postgres/blob/main/homework/task4.md

СПАСИБО ЗА ВНИМАНИЕ!

#аис
#учисьваис